
- 추론 **Inference**

- 추정 **Estimation**

- * 점추정 **Point estimation**

- * 구간추정 **interval estimation**

- 검정 **Test**

- **Point estimation**

- $X_1, \dots, X_n \stackrel{iid}{\sim} (\theta)$; random sample, n : sample size

- $T = T(x_1, \dots, x_n) : X_1, \dots, X_n$ 의 조합으로 이루어진 통계량 **statistic**, 확률변수

- X : 확률변수, x : 관측값 (관찰값)

- $\theta \in \Omega$, Ω : 모수공간

- 추정량 **estimator**

- $T : \theta$ 의 추정량, 추정량 \in 통계량

- $t = T(x_1, \dots, x_n) : \text{추정치}$ **estimate**

- 좋은 추정량의 조건

- unbiasedness : $E(T) - \theta = 0$

- * T 는 θ 의 불편추정량이다.

- **Maximum likelihood estimator**

- $X_1, \dots, X_n \stackrel{iid}{\sim} f(x; \theta) \Rightarrow$ 동일한 pdf $f(x; \theta)$ 를 갖는 분포로부터 뽑힌 독립인 n 개의 표본

- 목표 : θ 추정 - X_1, \dots, X_n 을 사용

- X_1, \dots, X_n 의 joint pdf

$$f(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

- θ 를 모수로 갖을때 ($X_1 = x_1, \dots, X_n = x_n$) 으로 관측될 가능성

- Change the role of X and θ

- $L(\theta; x_1, \dots, x_n)$ 가능도함수, $f(x_1, \dots, x_n; \theta)$ 의미 동일

- IDEA : 가능도함수 $L(\theta; x_1, \dots, x_n)$ 를 최대로 해주는 θ 를 θ 의 추정량으로 선택

- $\Rightarrow \hat{\theta}^{mle} = \underset{\theta \in \Omega}{\operatorname{argmax}} L(\theta; x_1, \dots, x_n) = \underset{\theta \in \Omega}{\operatorname{argmax}} \ell(\theta; x)$

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

$$\ell(\theta; x_1, \dots, x_n) = \log L(\theta; x_1, \dots, x_n)$$

$$= \sum_{i=1}^n \log f(x_i; \theta)$$

$\ell(\theta)$ 는 대부분 오목함수 **concave**

$$\frac{\partial \ell(\hat{\theta}^{mle})}{\partial \theta} = 0 \quad \Rightarrow \quad \text{Estimating Equation}$$

ex) Normal $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$, Find $\hat{\mu}^{mle}, \hat{\sigma}^{2mle}$.

$$\begin{aligned} L(\theta; x_1, \dots, x_n) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(x_i - \mu)^2}{2\sigma^2}\right\} \\ &= (2\pi)^{-\frac{n}{2}} (\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}\right\} \\ \ell(\theta; x_1, \dots, x_n) &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} \end{aligned}$$

①

$$\begin{aligned} \frac{\partial \ell}{\partial \mu} &= \frac{\sum_{i=1}^n (x_i - \mu)}{\sigma^2} \stackrel{set}{=} 0 \\ &\Leftrightarrow \sum_{i=1}^n (x_i - \mu) = 0 \\ &\Leftrightarrow \sum_{i=1}^n x_i = n\mu \\ &\therefore \mu = \bar{x}, \hat{\mu}^{mle} = \bar{x} \end{aligned}$$

②

$$\begin{aligned} \frac{\partial \ell}{\partial \sigma^2} &= -\frac{n}{2\sigma^2} + \frac{\sum_{i=1}^n (x_i - \mu)^2}{2} \frac{1}{\sigma^4} \stackrel{set}{=} 0 \\ &\Leftrightarrow \frac{-n\sigma^2 + \sum_{i=1}^n (x_i - \mu)^2}{2\sigma^4} = 0 \\ &\Leftrightarrow n\sigma^2 = \sum_{i=1}^n (x_i - \mu)^2 = 0 \\ &\therefore \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 \\ &\therefore \hat{\sigma}^{2mle} = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 \end{aligned}$$

ex) Uniform $X_1, \dots, X_n \stackrel{iid}{\sim} U(0, \theta)$, Find $\hat{\theta}^{mle}$

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n \frac{1}{\theta} I_{(0 \leq x_i \leq \theta)} \\ = \frac{1}{\theta^n} I_{(\min(x_i) \geq 0)} I_{(\max(x_i) \leq \theta)}$$

$\Rightarrow \frac{1}{\theta^n} : \theta$ 에 대한 감소함수 (θ 가 가장 작을때, $\frac{1}{\theta^n}$ 은 가장 커진다)

$$\therefore \theta = \max(x_i), \quad \hat{\theta}^{mle} = \max(x_i)$$

- **Confidence Intervals** : θ 가 속해있을 것이라 생각되는 구간을 제시

$$P(\theta \in [L, U]) = 1 - \alpha, \quad \alpha : \text{fixed value}$$

- $\alpha = 0$ 인 경우는 의미 없음 \Rightarrow 아무런 정보를 주지 않음
- α 를 적당히 작은 값으로 고정
- 구간 길이가 가장 작을때 좋은 구간추정량이다.

★ 구간추정, 검정을 어떻게 할것인가?

Pivot random variable (Pivotal quantity)

\Rightarrow 추정 대상 모수 θ 와 θ 의 좋은 점추정량으로 이루어진 **잘 알려진 분포**를 가지고 있는 확률 변수 \Rightarrow 확률 계산을 하기 위해 잘 알려진 분포를 따르는 확률변수를 사용한다.

- **Order statistics**

$X_1, \dots, X_n \stackrel{iid}{\sim} f(x; \theta) \Rightarrow \min(X_i) = Y_1 < Y_2 < \dots < Y_n = \max(X_i)$ 으로 재배열

$Y_k : X_1, \dots, X_n$ 중에서 크기가 k 번째로 작은 값

① Y_1, \dots, Y_n 의 joint pdf \Rightarrow 변수변환

$$g(y_1, \dots, y_n) = \begin{cases} n! f(y_1) \cdots f(y_n) & a < y_1 < \dots < y_n < b \\ 0 & elsewhere \end{cases}$$

X 를 나열하는 모든 경우의 수만큼의 항이 나오게 된다. 각 항은 $f(y_1) \cdots f(y_n) |J|$ 이다. 여기서 모든 항의 $|J|$ 은 1이다. 따라서 나열하는 모든 경우의 수 ($n!$) 만큼 $f(y_1) \cdots f(y_n)$ 의 합이 된다.

② Population median

$$F(x) = P(X \leq x) = \int_a^x f(w)dw, \quad a < x < b$$

$\Rightarrow F(m) = \frac{1}{2}, \quad m : \text{population median}$

ex) $n = 3$

$X_1, X_2, X_3 \stackrel{iid}{\sim} f(x) \Rightarrow Y_1 < Y_2 < Y_3, \quad Y_2 : \text{sample median}$

(1) Y_1, Y_2, Y_3 의 joint pdf

$$g(y_1, y_2, y_3) = \begin{cases} 6f(y_1)f(y_2)f(y_3) & a < y_1 < y_2 < y_3 < b \\ 0 & elsewhere \end{cases}$$

(2) Y_2 의 marginal pdf

$$\begin{aligned} h(y_2) &= \int_{y_2}^b \int_a^{y_2} 6f(y_1)f(y_2)f(y_3)dy_1dy_3 \\ &= \int_{y_2}^b 6f(y_2)f(y_3) \int_a^{y_2} f(y_1)dy_1dy_3 \\ &= 6f(y_2)F(y_2) \int_{y_2}^b f(y_3)dy_3 \\ &= \begin{cases} 6f(y_2)F(y_2)(1 - F(y_2)), & a < y_2 < b \\ 0, & elsewhere \end{cases} \end{aligned}$$

(3) Compute $F(m) = P(Y_2 \leq m)$

$$\begin{aligned} &= \int_a^m 6f(y_2)F(y_2)(1 - F(y_2))dy_2 \\ &= \int_a^m 6f(y_2)F(y_2) - 6f(y_2)F(y_2)^2 dy_2 \\ &= \left[6 \frac{F(y_2)^2}{2} - 6 \frac{F(y_2)^3}{3} \right]_a^m \\ &= 6 \left[\frac{F(m)^2}{2} - \frac{F(m)^3}{3} \right] \\ &= 3 \frac{1}{4} - 2 \frac{1}{8} = \frac{1}{2} \\ &= F_{y_2}(m) \end{aligned}$$

\Rightarrow 표본중위수 (Y_2) 의 중위수가 모집단의 중위수 (m) 가 된다.

③ Marginal pdf

ex) $n = 3$

$$\begin{aligned}
h(y_2) &= \int_{y_2}^b \int_a^{y_2} 6f(y_1)f(y_2)f(y_3)dy_1dy_3 \\
&= \int_{y_2}^b 6f(y_2)f(y_3) \int_a^{y_2} f(y_1)dy_1dy_3 \\
&= 6f(y_2)F(y_2) \int_{y_2}^b f(y_3)dy_3 \\
&= \begin{cases} 6f(y_2)F(y_2)(1 - F(y_2)), & a < y_2 < b \\ 0, & elsewhere \end{cases}
\end{aligned}$$

ex) $n = 4$

$$h(y_3) = \int \int \int 4!f(y_1)f(y_2)f(y_3)f(y_4)dydydy$$

(Generalization)

$$g_k(y_k) = \frac{n!}{(k-1)!(n-k)!1!} f(y_k)[F(y_k)]^{k-1}[1 - F(y_k)]^{n-k}$$

④ Heuristic derivation

$$P\left(x - \frac{\Delta}{2} \leq x \leq x + \frac{\Delta}{2}\right) \approx \Delta f(x) \quad (\text{밑변}) \times (\text{높이})$$

⑤ Joint pdf of any two order statistics ($Y_i < Y_j$)

$$g_{ij}(y_i, y_j) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} [F(y_i)]^{i-1} [F(y_j) - F(y_i)]^{j-i-1} [1 - F(y_j)]^{n-j} f(y_i)f(y_j)$$